

Trabalho Prático

Análise de Dados em Informática

Análise de Desempenho De Técnicas de Aprendizagem Automática

*Engenharia Informática - 3º ano 2º semestre
Ano Letivo 2025/2026*

-
1. Objetivos
 2. Calendarização
 3. Normas
 - 3.1 Artigo Científico
 - 3.2 Avaliação
 4. Descrição do Trabalho
 5. Referências Bibliográficas
-

1. Objetivos

1.1. Objetivo Geral:

- Análise de Desempenho de técnicas de aprendizagem automática

1.2. Objetivos Específicos:

- Definir a metodologia de trabalho
- Análise e Discussão dos Resultados com recurso ao Python
- Escrita de artigo científico

2. Calendarização

Entrega do trabalho: até **14 de junho de 2026 pelas 23:59**

Defesa e discussão: em data a marcar pelo Professor de PL

3. Normas

- Deverá resolver as tarefas propostas usando o Python.
- A **data final de ENTREGA** do trabalho é dia **14 de junho de 2025 pelas 23:59**, no moodle. Independentemente destes prazos, os grupos deverão ser capazes de, quando o professor o solicitar, reportar o estado de desenvolvimento do trabalho.
- A entrega do trabalho consta de um artigo científico (**máx. 8 páginas**) conforme *template* disponibilizado no moodle, apresentação *powerpoint* com resumo do trabalho realizado, entre outros. Deverá submeter todos os documentos num ficheiro compactado. O zip file deve conter:
 - artigo científico em pdf
 - dados utilizados em formato `xlsx`
 - Notebook completo (e comentado) do código criado em Python para resolver as tarefas propostas
 - apresentação PowerPoint com resumo do artigo para 10 minutos (ppt)
- O nome do ficheiro zip deverá seguir a seguinte notação:
ANADI_YYY_XXX_Nºaluno1_Nºaluno2_Nºaluno3.zip, onde **YYY** representa a sigla do docente das PL, e **XXX** representa a turma PL.

Exemplo: **ANADI_EFG_3DA3DB_7777777_8888888_9999999.zip**.
- Trabalhos cujo nome não respeite a notação indicada **serão penalizados em 10%**.
- **A entrega do trabalho deverá ser submetida no moodle até à data de entrega definida. Não serão aceites trabalhos fora do prazo.**
- A apresentação, **em formato de comunicação (10 minutos)**, e discussão dos trabalhos decorrerá em dia e hora a marcar por cada professor das teórico-práticas. No dia da apresentação, **TODOS** os elementos do grupo deverão estar presentes e apresentar uma das componentes do trabalho realizado e sistematizado na apresentação **ppt**. Os elementos ausentes ou que não sigam as orientações definidas para a realização da apresentação/defesa não terão classificação.
- A avaliação do trabalho será realizada pelo docente das aulas práticas-laboratoriais (PL).
- Cada grupo é responsável por gerir o seu processo de desenvolvimento. Dificuldades e problemas deverão ser comunicados atempadamente ao professor das aulas PL.
- Código de conduta: (cf. Regulamento Disciplinar dos Estudantes do IPP)
 - Nenhum estudante ou grupo pode assumir pertença de trabalho realizado por outrem ou desenvolvido em conluio.

- É expressamente proibido o uso de materiais, artefactos ou código de outrem sem a devida, e explícita indicação de origem.
 - Código de outras fontes deve ser claramente identificado no próprio código, indicando a fonte.
 - Casos de apropriação ilícita de materiais, artefactos e/ou código, sujeito a avaliação, serão reportados à Presidência do ISEP.
 - A utilização de ferramentas com IA de assistência à codificação/desenho (e.g. chatGPT) deve ser mencionada
- É obrigatório o uso da ferramenta de controle de versões GitHub. Devem partilhar o repositório com os vossos professores de PL's.

3.1. Artigo Científico

No Artigo Científico (máx. 8 páginas) deverão ser documentadas todas as fases da metodologia de trabalho seguida, contextualização do tema, exploração, preparação dos dados, análise e discussão dos resultados e conclusões.

Deve ser seguido o *template* IEEE disponibilizado no moodle (Word ou Latex).

3.2. Avaliação

Na avaliação do trabalho serão considerados os seguintes aspetos e ponderações (Tabela 1):

- Breve revisão do estado da arte (algoritmos de aprendizagem automática e análise de desempenho);
- O desenvolvimento de modelos de Aprendizagem Automática;
- A qualidade do processo de análise de dados seguido, a organização do código, a avaliação dos modelos criados, análise e discussão dos resultados e as conclusões alcançadas;
- Organização, qualidade da escrita, apresentação e clareza do artigo científico;
- A comunicação, defesa e discussão individual;
- A participação individual de cada um dos elementos em %.

Tabela 1 – Avaliação do Trabalho Prático 2

Contextualização (Abstract, Introdução (motivação, objetivos e metodologia seguida))	2 valores
Análise de desempenho de técnicas de aprendizagem automática (código Python – 30%; artigo científico (análise exploratória de dados, definição e avaliação dos modelos, análise e discussão dos resultados) – 70%)	10 valores
Conclusões	2 valores
Apresentação e Discussão individual e em grupo	6 valores

Nota: No momento da defesa do trabalho será validada a participação de cada um dos elementos do grupo, na concretização dos objetivos do trabalho e do grupo. A nota de cada um dos elementos do grupo será definida de acordo com a sua % de participação, bem como do seu desempenho na defesa e discussão individual.

4. Descrição do Trabalho

Com as tempestades que assolaram o nosso país neste último inverno, muitos são os desafios que se têm colocado no contexto da sustentabilidade e da gestão de recursos e energia. Este trabalho surge de um desafio colocado pela e-REDES [4] no qual se pretende avaliar de que forma a implementação de medidas de eficiência energética na iluminação pública (ex.: substituição por tecnologia LED) pode impactar a disponibilidade de potência nos Postos de Transformação de Distribuição (PTD). ***Com base nessa libertação potencial de capacidade, como será possível analisar e quantificar a viabilidade técnica para a instalação de carregadores para veículos elétricos (VE), sem comprometer a segurança e a qualidade do fornecimento elétrico?***

No contexto da emergência climática e da transição energética europeia, a descarbonização das cidades tornou-se um imperativo estratégico. Atualmente, a Iluminação Pública (IP) representa uma parcela significativa do consumo energético municipal, mas a transição acelerada para a tecnologia LED tem demonstrado um potencial disruptivo na libertação de carga na rede elétrica de baixa tensão.

Simultaneamente, a expansão da Mobilidade Elétrica enfrenta o desafio crítico da capacidade da rede. A instalação de pontos de carregamento de veículos elétricos (VE) exige uma disponibilidade de potência que, em muitas zonas urbanas, já se encontra próxima dos limites operacionais dos Postos de Transformação de Distribuição (PTD). Surge aqui uma oportunidade de sinergia: a "potência libertada" pela eficiência na IP pode ser o catalisador para a infraestrutura de VE, evitando investimentos massivos em novos PTDs.

Com este trabalho pretende-se analisar o impacto das estratégias de otimização da iluminação pública na reserva de potência dos Postos de Transformação. O objetivo principal é criar um modelo que quantifique a capacidade remanescente resultante desta modernização. Também é importante avaliar se é viável técnica e operacionalmente atribuir essa capacidade à mobilidade elétrica, sem comprometer a estabilidade e a fiabilidade da rede elétrica municipal. Neste sentido, pretende-se a aplicação de algoritmos de aprendizagem automática na análise de dados e respetiva comparação usando os testes estatísticos mais adequados. Deve ser produzido um artigo científico (português ou inglês), conforme *template* indicado, com o estado da arte sobre os diferentes algoritmos, os modelos desenvolvidos, os resultados obtidos, a análise e discussão dos resultados e as conclusões gerais do trabalho (síntese das conclusões).

No Trabalho Prático 1 (TP1) foi realizada uma análise estatística exploratória ao nível do concelho, permitindo identificar padrões globais relacionados com a infraestrutura elétrica, a iluminação pública e os níveis de ocupação da rede. No Trabalho Prático 2 (TP2), pretende-se evoluir dessa abordagem agregada para uma análise mais detalhada ao nível do posto de transformação (PTD) o que permite a aplicação de técnicas de aprendizagem automática para previsão e classificação.

No âmbito da 2ª iteração do Trabalho Prático, deve utilizar os dados disponíveis no ficheiro `PTD_level_dataset.xlsx`, que resulta da junção dos ficheiros:

- `IP_data.xlsx` (Iluminação Pública)
- `PTD_data.xlsx` (Postos de Transformação)

A junção foi realizada com base na variável **CodDistritoConcelho** permitindo associar a cada PTD as características do respetivo concelho. O *dataset* contém aproximadamente 72.000 registos, correspondendo aos PTDs distribuídos por Portugal. O *dataset* inclui as seguintes variáveis (Tabela 2):

Tabela 2 – Descrição das variáveis do dataset

Nível do PTD	Agregadas ao Concelho:	Variáveis derivadas:
Cap_PTD_kVA	P_IP_Total	PFolga_PTD
N_Clientes	Rate_Ineficiencia	Cap_per_Cliente
Pot_Contratada_kVA	LED_Ratio	IP_per_PTD
Tipo Construtivo		

Pretende-se a realização da análise exploratória dos dados disponibilizados, desenvolvendo modelos de regressão e classificação que foram estudados, ao longo do semestre: regressão linear/múltipla, árvores de decisão, k-vizinhos-mais-próximos, redes neuronais e SVM [1-3]. Devem ser tidas em consideração as variáveis calculadas na 1ª iteração, nomeadamente **Ganho LED (ΔP_{LED})**, **Folga Rede (P_{Folga})**, **Carga VE (P_{VE})**, **Saldo Final de Viabilidade (D)**, e **Rate Ineficiencia**. Outras variáveis podem ser calculadas, desde que justificados os pressupostos.

4.1. Análise Exploratória de Dados

1. Comece por carregar o ficheiro, verifique a sua dimensão e obtenha um sumário dos dados.
2. Faça a exploração dos dados através dos gráficos mais apropriados.
3. Realize o pré-processamento dos dados, incluindo:
 - tratamento de valores omissos
 - transformação de variáveis categóricas
 - normalização/standardização quando necessário
 - seleção de variáveis relevantes

Nota: Nem todas as variáveis fornecidas são adequadas para modelação. A seleção de variáveis relevantes faz parte do trabalho e será valorizada.

4.2. Regressão

Nesta tarefa, o objetivo é prever o valor contínuo da Folga Rede por PTD ($PFolga_PTD$), métrica que determina a capacidade de um PTD em absorver a mobilidade elétrica.

1. Crie um diagrama de correlação entre a variável $PFolga_PTD$ e as restantes variáveis e interprete.
2. Usando o método ***k-fold cross validation*** obtenha um modelo regressão linear simples para a variável $PFolga_PTD$ usando uma variável explicativa relevante e justifique a escolha.
 - a) Apresente a função linear resultante
 - b) Visualize a reta correspondente ao modelo de regressão linear simples e o respetivo diagrama de dispersão.
 - c) Calcule o erro médio absoluto (MAE) e raiz quadrada do erro médio (RMSE) do modelo
3. Usando o método ***k-fold cross validation*** desenvolva modelos para prever a $PFolga_PTD$ usando:
 - a) Regressão linear múltipla.
 - b) Árvore de regressão. Apresente a árvore de regressão obtida.
 - c) SVM. Otimize o kernel.
 - d) Rede neuronal. Deve ser realizada uma optimização estruturada da rede, incluindo: (1) ensaio de pelo menos três configurações, variando a profundidade, o número de neurónios por camada e a presença de regularização (L2 ou dropout); (2) apresentação das curvas de loss de treino e validação para avaliar a existência de overfitting/underfitting; (3) discussão da influência da learning rate e do early stopping.
4. Compare os resultados obtidos pelos modelos referidos na questão anterior, usando o erro médio absoluto (MAE) e a raiz quadrada do erro médio (RMSE) e identifique as variáveis mais relevantes.
5. Para os dois melhores modelos de regressão, apresente as curvas de aprendizagem (training score vs. validation score). Interprete os resultados obtidos: o treino dos modelos foi eficiente, ou há sinais de overfitting ou underfitting? Esta análise deve ser incluída no artigo científico.
6. Justifique se os resultados obtidos para os dois melhores modelos são estatisticamente significativos (para um nível de significância de 5%) usando testes estatísticos adequados e identifique o(s) modelo(s) com melhor desempenho.

4.3. Classificação

Nesta tarefa, o objetivo será prever o nível de ocupação da rede. Com base na distribuição de `Util_Decimal`, derive um novo atributo `utilizRede` com três valores: baixo, médio, alto. A discretização pode ser feita com base em intervalos definidos ou quantis. A escolha deve ser justificada.

1. Usando o método ***k-fold cross validation*** desenvolva modelos de previsão de `utilizRede` usando os seguintes métodos:
 - a) Árvore de decisão.
 - b) Rede neuronal. Deve ser realizada uma otimização, estruturada da rede, incluindo: (1) ensaio de pelo menos três configurações, variando a profundidade e o número de neurónios por camada; (2) apresentação das curvas de loss de treino e validação para avaliar a existência de overfitting / underfitting; (3) discussão da influência da learning rate e do early stopping.
 - c) SVM. Optimize o kernel.
 - d) K-vizinhos-mais-próximos. Optimize o parâmetro K.
2. Obtenha a média e o desvio padrão da ***Accuracy; Precision; Recall*** e ***F1-score*** (por classe) com os modelos obtidos na alínea anterior.
3. Para os modelos das árvores de decisão, apresente e visualize a importância de features. Discuta os resultados, fazendo uma comparação com as correlações identificadas na Secção 4.1.
4. Verifique se existe diferença significativa no desempenho dos dois melhores modelos obtidos anteriormente usando testes estatísticos adequados (use um nível de significância de 5%). Identifique o modelo que apresenta o melhor desempenho.
5. Compare os resultados dos modelos. Discuta em detalhe qual o modelo que apresentou melhor e pior desempenho de acordo com os critérios: ***Accuracy; Precision; Recall*** e ***F1-score***. (Deve apresentar as curvas de aprendizagem desses modelos, de forma a avaliar a eficiência do treino, discutindo de que forma isso influência os resultados).
6. Com base nas tarefas desenvolvidas e nos resultados alcançados, proceda à identificação das principais limitações associadas aos dados e/ou aos modelos utilizados, propondo estratégias que possam contribuir para a melhoria do desempenho dos modelos. A discussão deverá ser sustentada nos resultados experimentais obtidos e integrada no artigo científico.

Ter em consideração que em todas as questões devem ser justificados os pressupostos assumidos, e os resultados devem ser interpretados e analisados. O artigo científico deve incluir a descrição de todos os modelos desenvolvidos, decisões e pressupostos assumidos na parametrização e a análise, interpretação e discussão dos resultados.

Referências Bibliográficas

- [1]. CHRISTOPHER BISHOP, PATTERN RECOGNITION AND MACHINE LEARNING. SPRINGER, 2006.
- [2]. TOM MITCHELL, MACHINE LEARNING. MCGRAW-HILL, 1997.
- [3]. WES MCKINNEY, PYTHON FOR DATA ANALYSIS: DATA WRANGLING WITH PANDAS, NUMPY, AND JUPYTER, 3RD EDITION, [HTTPS://WESMCKINNEY.COM/BOOK/](https://wesmckinney.com/book/), O'REILLY MEDIA, 2022.
- [4]. E-REDES, <https://www.e-redes.pt/pt-pt>