Trabalho Prático 1

Análise de Dados em Informática

Engenharia Informática - 3º ano 2º semestre
Ano Letivo 2025/2026

---

1. Objetivos
2. Calendarização
3. Normas
3.1 Artigo Científico
3.2 Avaliação
4. Descrição do Trabalho
5. Referências Bibliográficas

---

1. Objetivos

Objetivo Geral:

- Análise Exploratória de Dados
- Análise Inferencial
- Correlação e Regressão

Objetivos específicos:

- Definir a metodologia de trabalho
- Análise e discussão dos resultados com recurso ao Python
- Escrita de Artigo Técnico com a Análise de Dados

2. Calendarização

Lançamento das propostas de trabalhos: até 2 de março de 2026
Entrega do trabalho: até **29 de março de 2026** (23:55)
Defesa e discussão: em data a marcar pelo professor de PL

3. Normas

- O grupo (**máx 3 elementos**) deve ser o mesmo nas 2 iterações do Trabalho Prático.
- Deverá ser usado o Python como ferramenta de suporte ao tratamento de dados.
- A **data final de ENTREGA** do 1º Trabalho Prático é **29 de março de 2026**, no moodle. Independentemente deste prazo, os grupos deverão ser capazes de, quando o professor o solicitar, reportar o estado de desenvolvimento do trabalho.
- A submissão do trabalho no moodle é efetuada **obrigatoriamente** através de um ficheiro compactado. Este ficheiro deverá conter:
    - artigo científico em pdf
    - dados utilizados em formato csv/excel
    - notebook completo (script completo e comentado) do código criado em Python para resolver as tarefas propostas, incluindo o dashboard
    - apresentação PowerPoint com resumo do artigo para 10 minutos (ppt)
- O nome do ficheiro deverá seguir a seguinte notação:

  ANADI_YYY_XXX_Nºaluno1_Nºaluno2_Nºaluno3.zip, onde **YYY** representa a sigla do docente das PL, e **XXX** representa a turma PL.

  Exemplo: **ANADI_AIM_3DA_7777777_8888888_9999999.zip.**

- Trabalhos cuja designação não respeite a notação indicada, **serão penalizados em 10%.**
- **A entrega do trabalho deverá ser submetida no moodle até à data de entrega definida. Não serão aceites trabalhos fora do prazo.**
- A defesa e discussão dos trabalhos decorrerá em dia e hora a marcar por cada professor das teórico-práticas. No dia da apresentação, **TODOS** os elementos do grupo deverão estar presentes. Os elementos ausentes não terão classificação. A defesa e discussão serão realizadas em grupo com questões direcionadas a cada elemento individualmente.
- Cada grupo é responsável por gerir o seu processo de desenvolvimento. Dificuldades e problemas deverão ser comunicados atempadamente ao professor das aulas práticas-laboratoriais.
- Código de conduta: (cf. Regulamento Disciplinar dos Estudantes do IPP)
    - Nenhum estudante ou grupo pode assumir pertença de trabalho realizado por outrem ou desenvolvido em conluio.
    - É expressamente proibido o uso de materiais, artefactos ou código de outrem sem a devida, e explícita indicação de origem.
    - Código de outras fontes deve ser claramente identificado no próprio código, indicando a fonte.
    - Casos de apropriação ilícita de materiais, artefactos e ou código sujeito a avaliação serão reportados à Presidência do ISEP.
    - A utilização de ferramentas com IA de assistência à codificação/desenho (e.g. chatGPT) deve ser mencionada.
- É obrigatório o uso da ferramenta de controle de versões Bitbucket.

3.1. Artigo Científico

No artigo científico deverão ser documentadas todas as fases da metodologia de trabalho seguida, preparação e exploração dos dados, análise e discussão dos resultados e conclusões (**máximo de 8 páginas** com o *template* do IEEE disponibilizado no moodle). O artigo deverá conter:

- **Secção Inicial:** Resumo; Introdução e Contextualização; Objetivos; resumo de todas as técnicas estatísticas usadas na realização das tarefas.
- **Secção final:** Conclusão e Referências, resumo das principais conclusões retiradas da resolução das diferentes tarefas colocadas no enunciado.
- Cada problema resolvido deverá ter uma breve explicação da técnica estatística e uma conclusão baseada na interpretação e analise dos resultados obtidos. Caso considere relevante deverá incluir uma síntese destas conclusões na secção final de conclusões.

3.2. Avaliação

Na avaliação do trabalho serão considerados os seguintes aspetos e as ponderações especificadas na tabela 1:

a) Contextualização (Sumário, Introdução (motivação, objetivos e metodologia seguida))
b) Qualidade do código Python e respetiva documentação
c) A qualidade do processo de análise de dados seguido, a organização do código, a avaliação dos modelos criados e as conclusões alcançadas
d) Organização, qualidade da escrita, apresentação e clareza do artigo
e) A defesa e discussão
f) Participação individual de cada um dos elementos

Tabela 1 – Grelha de avaliação do Trabalho Prático 1

Dashboard	5%
Contextualização (Sumário, Introdução (motivação, objetivos e metodologia seguida))	10%
Manipulação de Dados (ETL)	10%
Análise Exploratória de Dados	15%
Análise de Inferência Estatística	20%
Modelo Preditivo	10%
Conclusão e referências	10%
Apresentação e Discussão	20%

Nota: A nota de cada um dos elementos do grupo será definida de acordo com a sua participação (em %). A nota de cada um dos elementos do grupo será definida de acordo com a sua % de participação. No momento da defesa do trabalho será validada a participação de cada um dos elementos do grupo, na concretização dos objetivos do trabalho e do grupo. **Os elementos ausentes não terão classificação.**

4. Descrição do Trabalho

Na realização do Trabalho Prático 1 pretende-se que os alunos desenvolvam o processo de pré-processamento de dados, Análise Exploratória de Dados, Análise Inferencial, Correlação e Regressão [1-3].

Com as tempestades que assolaram o nosso país nas últimas semanas e particularmente a Kristin, muitos são os desafios que se têm colocado no contexto da sustentabilidade e da gestão de recursos e energia.

Este trabalho surge de um desafio colocado pela e-REDES [4] no qual se pretende avaliar de que forma a implementação de medidas de eficiência energética na iluminação pública (ex.: substituição por tecnologia LED) pode impactar a disponibilidade de potência nos Postos de Transformação de Distribuição (PTD). ***Com base nessa libertação potencial de capacidade, como será possível analisar e quantificar a viabilidade técnica para a instalação de carregadores para veículos elétricos (VE), sem comprometer a segurança e a qualidade do fornecimento elétrico?***

Introdução: Enquadramento e Contexto Atual

No contexto da emergência climática e da transição energética europeia, a descarbonização das cidades tornou-se um imperativo estratégico. Atualmente, a Iluminação Pública (IP) representa uma parcela significativa do consumo energético municipal, mas a transição acelerada para a tecnologia LED tem demonstrado um potencial disruptivo na libertação de carga na rede elétrica de baixa tensão.

Simultaneamente, a expansão da Mobilidade Elétrica enfrenta o desafio crítico da capacidade da rede. A instalação de pontos de carregamento de veículos elétricos (VE) exige uma disponibilidade de potência que, em muitas zonas urbanas, já se encontra próxima dos limites operacionais dos Postos de Transformação de Distribuição (PTD). Surge aqui uma oportunidade de sinergia: a "potência libertada" pela eficiência na IP pode ser o catalisador para a infraestrutura de VE, evitando investimentos massivos em novos PTDs.

Com este trabalho pretende-se analisar o impacto das estratégias de otimização da iluminação pública na reserva de potência dos Postos de Transformação. O objetivo principal é criar um modelo que quantifique a capacidade remanescente resultante desta modernização. Também é importante avaliar se é viável técnica e operacionalmente atribuir essa capacidade à mobilidade elétrica, sem comprometer a estabilidade e a fiabilidade da rede elétrica municipal.

Para a realização deste trabalho deve utilizar os dados disponíveis nos ficheiros **`IP_data.xlsx`** e **`PT_data.xlsx`**. Estes dados são provenientes de:

- https://e-redes.opendatasoft.com/pages/homepage/
- https://e-redes.opendatasoft.com/explore/dataset/postos-transformacao-distribuicao/table/
- https://e-redes.opendatasoft.com/explore/dataset/cadastro_iluminacao_publica/table/

Use um nível de significância de 5% em todos os testes de hipóteses a efetuar.

4.1. Dashboard

O desenvolvimento de um *dashboard* interativo com:

- Perfis horários de consumo da iluminação pública (antes vs. depois)
- Capacidade instalada e capacidade disponível nos PTD
- Estimativa de potência libertada pelas medidas de eficiência
- Cenários de integração de carregadores de VE e respetivo impacto na carga do PTD
- Mapa das zonas analisadas com indicação dos PTD, iluminação pública e locais potenciais para carregamento

4.2. Manipulação de Dados

Antes de efetuar a análise estatística, deve ser efetuado o seguinte processamento dos dados:

1. **Processamento da Iluminação Publica (*IP_data*)**
   - Criar variável binária ***Is_Ineficiente***:
     – 1: Tipo de Lâmpada ∈ {Sódio, Mercúrio}
     – 0: Outros tipos.

   - Criar variável **Potência kW**:

$$\text{Potência kW} = \frac{\text{Potencia Instalada Total (kW)}}{1000}$$

   - Agrupar por ***CodDistritoConcelho*** para obter:
     – ***P_IP_Total***: soma da Potência kW de todas as linhas de IP do concelho.
     – ***P_IP_Inef*** : soma da Potência kW das linhas onde ***Is_Ineficiente*** == 1.

2. **Processamento dos Postos de Transformação (PTD data)**
   - Converter ***'Nível de Utilização [%]'***: conversão para valores decimais (Ex: '60%-79%' → 0.79).
   - Agrupar por ***CodDistritoConcelho*** para obter:
     – ***Cap_PTD***: soma da potência instalada [kVA] de todos os PTDs do concelho.
     – ***Util_Media***: média do Nível de Utilização de todos os PTDs do concelho.
     – ***N_PTDs***: número de PTDs de cada concelho.

3. **Variáveis do Novo Dataset**

No novo dataset, devem ser criadas as seguintes variáveis:

- **Ganho LED (ΔP_{LED})**: Representa a potência a ser libertada pela substituição de lâmpadas ineficientes por tecnologia LED.

$$\Delta P_{LED} = P_IP_Inef \times 0.65$$

- **Folga Rede (P_{Folga})**: Estima a capacidade disponível na rede, descontando a utilização atual e aplicando uma margem de segurança de 92%.

$$P_{Folga} = (Cap_{PTD} \times 0.92) \times (1 - Util_{Media})$$

- **Carga VE (P_{VE})**: Projeta o aumento de carga necessário para instalar carregadores de 22 kW em todos os PTDs do concelho.

$$P_{VE} = NPT\ Ds \times 22 \times 0.60$$

- **Saldo Final de Viabilidade (D)**: O indicador que subtrai a nova carga (PVE) à capacidade total disponível ($P_{Folga} + \Delta P_{LED}$), determinando se o projeto é viável.

$$D = P_{Folga} + \Delta P_{LED} - P_{VE}$$

- ***Rate Ineficiencia***: O rácio que mede o peso da tecnologia obsoleta face ao total da iluminação do concelho.

$$\text{Rate Ineficiencia} = Rate\ Ineficiencia = \frac{P_IP_Inef}{\text{P_IP_Total}}$$

4.3. Análise e Exploração de Dados

1. Construa uma representação gráfica que permita visualizar o mix tecnológico (LED vs. Convencional). Identifique se a maioria da potência ineficiente se concentra num grupo restrito de municípios.
2. Construa boxplots para comparar as distribuições dos níveis de utilização dos PTDs entre os distritos de Lisboa, Porto, Aveiro e Setúbal. Identifique o distrito com maior variabilidade de carga.
3. Quantifique a prevalência de valores omissos ou indeterminados (N/D, <20). Utilize uma representação gráfica para identificar a presença de outliers nos níveis de ocupação da rede.
4. Construa uma tabela com a média, quartis, desvio padrão, assimetria e curtose do nível de utilização médio para os concelhos de Coimbra, Évora, Braga e Faro (apresente com 4 casas decimais).

4.4. Inferência Estatística

1. Considere a base de dados consolidada e selecione aleatoriamente uma amostra de 50 concelhos. Use esta amostra para testar se o nível médio de ocupação da rede é inferior a um patamar de referência (ex: 60\%), verificando previamente a normalidade dos dados.
2. Selecione aleatoriamente duas amostras de 30 registos: uma de concelhos "Modernizados" (rácio de LED acima da mediana) e outra de concelhos "Ineficientes". Use estas amostras para testar se o estado médio de ocupação da rede difere significativamente entre os dois grupos.
3. Considere três amostras aleatórias de 25 concelhos representativas de diferentes perfis de ocupação da rede: Norte/Centro Litoral (Porto, Braga, Coimbra), Lisboa e Litoral Sul (Lisboa, Setúbal, Aveiro) e Interior/Alentejo (Évora, Beja, Portalegre). Use estas amostras para testar a existência de diferenças significativas nos níveis médios de carga da rede (ANOVA). Caso necessário, efetue uma análise post-hoc adequada.
4. Teste a existência de uma relação linear estatisticamente significativa entre a capacidade total de transformação instalada e a carga de iluminação pública para a totalidade dos concelhos, interpretando o coeficiente de correlação de Pearson.

4.5. Correlação e Regressão - Modelo Preditivo

Considere os dados relativos aos níveis médios de carga dos PTDs nos distritos de Aveiro, Porto, Lisboa e Braga e construa uma tabela de correlação entre as principais métricas de infraestrutura (Capacidade PTD e Potência IP) para estes distritos. Selecione os dados relativos a Portugal Continental. Considere as seguintes variáveis explicativas:

- X1 – Potência Instalada Total de Iluminação Pública (***P_IP_Total***)
- X2 – Capacidade Nominal de Transformação (***Cap_PTD***)
- X3 – Ineficiência (***Rate_Ineficencia***)

e a variável dependente:

- Y – Estado de Ocupação Médio da Rede (***Util_Media***).

1. Determine o modelo de regressão linear múltipla que explique a variação de Y em função de X1, X2 e X3.
2. Verifique as condições sobre os resíduos (normalidade, independência e homocedasticidade).
3. Verifique se existe multicolinearidade entre as variáveis recorrendo ao cálculo do VIF (*Variance Inflation Factor*).
4. Comente o modelo obtido tendo em conta o coeficiente de determinação ajustado e a significância estatística dos preditores.
5. Estime o nível de ocupação esperado (Y) para os concelhos com os códigos: 101, 102, 103, 104, 105, 106, 107, 108 e 109 (Distrito de Aveiro) e compare as previsões com os valores reais presentes no *dataset*.
6. Com base no coeficiente β_3 obtido no modelo, quantifique a redução esperada no nível de ocupação da rede caso o rácio de ineficiência tecnológica seja reduzido em 20\% através da implementação de tecnologia LED.
7. Utilize o modelo para identificar os concelhos onde a libertação de potência é estatisticamente mais viável para a instalação de carregadores de veículos elétricos de 22 kW, justificando com base nos intervalos de confiança das previsões.

4.6. Análise e Discussão de Resultados

Efetue uma síntese dos resultados e das conclusões, obtidos neste trabalho, que considera mais importantes, justificando sempre que necessário (conclusão). Use um nível de significância de 5% em todos os testes de hipótese que realizar.

5. Referências Bibliográficas

[1]. C. Heumann and Shalabh M. Schomaker, Introduction to statistics and data analysis, Springer International Publishing, 2016.

[2]. Douglas C. Montgomery, Design and Analysis of Experiments, 8th edition. John Wiley & Sons, New York, 2013.

[3]. Wes Mckinney, Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter, 3rd edition, https://wesmckinney.com/book/,O'Reilly Media, 2022.

[4]. e-REDES, https://www.e-redes.pt/pt-pt